



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

مروری گذرا بر مقالات تولید تصاویر فراوضوح از تک تصویر با کمک شبکه‌های پیچشی

کریم شاهی نیار^۱، محمد علی بالافر^{۲*}

۱- هوش مصنوعی و رباتیک، دانشکده مهندسی برق و کامپیوتر، دانشگاه تبریز، تبریز، ایران

۲- رئیس گروه علوم کامپیوتر، دانشکده مهندسی برق و کامپیوتر، دانشگاه تبریز، تبریز، ایران

*نویسنده مسئول: Balafarila@yahoo.com

خلاصه

در این مقاله تلاش داریم تا یک مرور گذرا بر تولید تصاویر فراوضوح، از تصاویر تک، در دنیای واقعی را داشته باشیم، هدف (های) این تحقیق، آشنا کردن پژوهشگران ایرانی با موضوع تولید تصاویر فراوضوح، با کمک شبکه‌های عمیق و شبکه‌های نو ظهور لبه دانش در حوزه هوش مصنوعی است، ما چندین مقاله‌ی مروری و مقاله‌های با ایده‌های نوآورانه را مطالعه کرده و خلاصه‌ای گذرا را ارائه کردیم، روش‌های قدیمی و جدید در لبه دانش را توضیح دادیم، معایب و مزایای هر یک را بیان کردیم، دیتاست‌های مورد استفاده را نام برده و معرفی کردیم. انتظار داریم پژوهشگرانی که این مقاله را مطالعه بکنند، یک دید کلی بر روی موضوع تولید تصاویر فراوضوح را بدست آورده و ایده‌هایی برای بهبود روش‌های قبلی پیشنهاد بدهند.

کلمات کلیدی: فراوضوح، شبکه‌های عمیق، شبکه‌های پیچشی، هوش مصنوعی، شبکه‌های مولد متخاصم

۱. مقدمه

مسئله‌ی تولید تصویر با وضوح^۱ بالا (فراوضوح)، از تصویر با وضوح پایین، یکی از چندین نوع مسئله در زمینه تولید تصاویر فراوضوح است. در کل، گونه‌های مختلفی از مسئله‌های فراوضوح، با محدودیت‌های متفاوت، توسط پژوهشگران مورد مطالعه قرار گرفته است. از جمله فراوضوح کردن ویدیو^{[4][5]}، فراوضوح کردن تصویر (تک تصویر^{[6][7]})، چندین تصویر^{[8][9]}، در فراوضوح کردن تصویر، باید از چندین نظر، از جمله، ارزیابی ذهنی^۲ و ارزیابی عینی^۳، بهبود حاصل شود^[10]. منظور از ارزیابی ذهنی همان ادراک ذهنی انسان است، و منظور از ارزیابی عینی، ارزیابی بر مبنای ریاضی، برای درک سیستم بصری چشم انسان است. نتایج حاصل، به صورت عددی ارزیابی می‌شود. منظور از بهبود، بهبود در نتایج ارزیابی مدل پیشنهادی با نتایج مدل‌های پیشین است. وضوح در تصاویر دیجیتال^۴، یعنی تراکم پیکسل^۵ (واحد نمایش

¹ Resolution

² subjective evaluation

³ objective evaluation

⁴ Digital Image

⁵ Pixel



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

تصاویر دیجیتال) بیشتر، که جزئیات^۱ و لبه‌ها^۲، آشکارتر از تصویر (های) با وضوح پایین‌تر دارد، است. بالا بردن وضوح تصویر را می‌توان به قبل و بعد از بکارگیری رویکردهای مبتنی بر یادگیری عمیق، تقسیم بندی کرد. قبل از بکارگیری یادگیری عمیق برای افزایش وضوح تصاویر، نصراللهی و همکاران [11]، روش‌های مورد استفاده را به سه گروه مختلف، یعنی روش‌های مبتنی بر درون‌یابی^۳، روش‌های مبتنی بر بازسازی^۴ و روش‌های مبتنی بر یادگیری^۵ طبقه‌بندی کردند. برای بازسازی تصاویر با وضوح بالا، بیشتر از روش‌های مبتنی بر درون‌یابی و منظم‌سازی استفاده می‌کردند. درون‌یابی، یک روشی برای افزایش تعداد پیکسل‌های تصویر است، که بعد از قرار دادن مقادیر ماتریس تصویر کوچک‌تر، در مکان‌های متناظر در ماتریس بزرگ‌تر، اقدام به پر کردن خانه‌های خالی ماتریس بزرگ‌تر، با روش‌های مبتنی بر خطی^۶، مبتنی بر مربعی^۷، مبتنی بر مکعبی^۸ و روش‌های متنوع دیگر، می‌کنند [13][12].

در سال ۲۰۱۴ اولین ایده برای بکارگیری روش‌های مبتنی بر شبکه‌های عصبی پیچشی^۹، برای افزایش وضوح تصویر، توسط دونگ و همکاران پیشنهاد شد [14]، از آن زمان محققان با الهام از روش‌های پیشین (روش‌های یادگیری عمیق) و با ترکیب ساختارها، حذف و اضافه کردن بخش‌هایی از شبکه‌ها، رفع ایرادات روش‌های پیشین، بهبود داده‌ها یا تولید داده‌های جدید، پیشنهاد شبکه‌های جدید و غیره، تلاش دارند تا سرعت زمان اجرا را افزایش بدهند، منابع حافظه را مدیریت کنند (با منابع کمتر به نتایج بهتر دست یابند) و به بهبود در خروجی تصویر فراوضوح نهایی، نسبت به الگوریتم‌های مشابه، دست یابند. برای ارزیابی تصویر خروجی، بعد از فرایند فراوضوح، چندین روش پیشنهاد شده است، نسبت پیک سیگنال به نویز^{۱۰}، و شاخص تشابه ساختاری^{۱۱}.

۲. مفاهیم اولیه

معیارهای اندازه‌گیری و ارزیابی برای تصاویر با وضوح بالا به طور کلی به دو نوع: ارزیابی ذهنی و ارزیابی عینی تقسیم می‌شوند. معیار ارزیابی ذهنی مبتنی بر ادراک انسان و معیار ارزیابی عینی مبتنی بر کیفیت تصویر می‌باشد. محدودیت‌های ارزیابی ذهنی، اول، نتیجه ارزیابی به راحتی تحت تاثیر ترجیحات شخصی قرار می‌گیرد و دوم، فرایند ارزیابی اغلب پرهزینه است و نمی‌توان آن را خودکار کرد. در مقابل، در ارزیابی عینی هم استفاده راحت‌تر و آسان‌تر است، هرچند نتایج با معیارهای ارزیابی مختلف ممکن است لزوماً با یکدیگر و همچنین ارزیابی ذهنی ناسازگار باشد.

۲.۱. معیارهای اندازه‌گیری

نسبت پیک سیگنال به نویز، به اختصار PSNR، روشی ریاضی و مبتنی بر آمار پیکسل‌های تصویر است. اندازه‌گیری کیفیت تصویر بدست آمد با محاسبه تفاوت بین مقادیر مقیاس خاکستری پیکسل تصویر حاصله مربوط به

¹ detail

² edge

³ interpolation-based preprocessing-based model

⁴ Reconstruction-based methods

⁵ Learning-based methods

⁶ linear

⁷ bilinear

⁸ bicubic

⁹ Convolution Neural Network

¹⁰ peak signal-to-noise ratio (PSNR)

¹¹ structural similarity index (SSIM)



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

تصویر اصلی. هرچقدر، مقدار ن.پ.س.ن بزرگتر باشد، تفاوت بین تصویر اصلی و تصویر فراوضوح بدست آمده، کمتر است. کاربردهایی از قبیل حذف نویز و ارزیابی وضوح تصویر فراوضوح دارد. ایرادی که دارد، عوامل بصری محلی، چشم انسان، در نظر گرفته نمی‌شود. در مورد سیستم بینایی انسان، حساسیت به نواحی مختلف متفاوت است و درک یک ناحیه خاص تحت تاثیر نواحی مجاور اصراف قرار می‌گیرد، بنابراین نتایج ارزیابی PSNR ممکن است از درک چشم انسان منحرف شود. شباهت ساختاری، به اختصار SSIM، شباهت ساختاری را اندازه‌گیری می‌کند. به طور خاص مقایسه‌ها به طور مشترک در جنبه‌های روشنایی، کنتراست و ساختار می‌باشد. با توجه به ساختار بالای تصاویر طبیعی، یک همبستگی قوی بین پیکسل‌های آنها وجود دارد که اغلب حاوی اطلاعات ضروری در مورد ساختار جسم است. سیستم بینایی انسان عمدتاً، اطلاعات ساختاری را از ناحیه مرئی به دست می‌آورد بنابراین، می‌توان اطلاعات دانش تشریبی اعوجاج تصویر را با تشخیص زوال اطلاعات ساختاری، درک کرد. SSIM از سه ماژول تشکیل شده است، روشنایی، کنتراست و ساختار. ابتدا از میانگین سطح خاکستری برای تخمین روشنایی استفاده می‌کنیم، سپس از انحراف معیار برای تخمین کنتراست استفاده می‌شود [46][47]. معیارهای دیگر ارزیابی از قبیل معیار وفاداری^۱، شباهت وصله‌ی تصویر آموخته شده^۲، ارزیابی طبیعت کیفیت تصویر^۳، پیش‌بینی امتیازات ادراکی تصاویر^۴ [48] و ارزیابی کیفیت مبتنی بر ادراک^۵، که ما در این پژوهش این موارد را بررسی نمی‌کنیم.

۲.۲. اهمیت موضوع

مسئله افزایش وضوح تصویر (ها)، کاربردهای بسیار گسترده‌ای در حوزه‌ی هوش مصنوعی و شاخه‌ی بینایی ماشین دارد. برای نخستین بار این مسئله در ساختار کلی‌تر، از قبیل، حذف نویز، افزایش کنتراست، کاهش و یا افزایش روشنایی تصویر (هایی) که ثبت شده بودند، مطرح شد. اما امروزه با پیشرفت‌های گسترده‌ای که در زمینه تکنولوژی رخ داده است، از راه‌حل‌های این مسئله، در ثبت تصاویر برخط و تصویر (هایی) که قبلاً ثبت شده‌اند و برای کاربردهایی از قبیل، امنیتی [15][16][17]، پزشکی [21][22][20][19][18]، رباتیک^۶ [23] و غیره استفاده می‌شود. با در نظر گرفتن بد و سخت بودن مسئله و با توجه به اینکه معمولاً عواملی از قبیل نویز، تاری، اعوجاج، پایین بودن وضوح تصویر موجود، در دسترس نبودن سخت افزار ثبت تصاویر با وضوح بالا، ناممکن بودن و یا در دسترس نبودن ثبت دوباره تصویر و غیره وجود دارد، مسئله‌ی تولید تصویر فراوضوح، می‌تواند راه‌حل‌های مناسب‌تری، برای مشکلات این حوزه ارائه دهد. گونه‌های مختلفی از مسائل تولید تصاویر فراوضوح در [1][2][26][21][25][24] بیان شده است. هر ساله، چندین مسابقه، در حوزه‌ی فراوضوح کردن تصویر، در مجله‌ها و کنفرانس‌های معتبر دنیا، برگزار می‌شود، از جمله، روندهای جدید در بازسازی و بهبود تصویر^۷ (NTIRE)، که در کنفرانس بینایی ماشین و تشخیص الگو^۸ برگزار می‌شود و اهدافی از جمله، معرفی یک دیتاست جدید، دست‌آوردهای در لبه دانش فراوضوح، مقایسه الگوریتم‌های مختلف و غیره [24] و بازیابی و دستکاری تصویر ادراکی^۹ (PIRM)، که در کنفرانس بینایی ماشین اروپا^۱ برگزار می‌شود، در این چالش، تمرکز اصلی بر روی کیفیت ادراکی تصویر است [24]، را می‌توان نام برد.

¹ IFC

² Large scale perceptual similarity dataset, evaluate the perceptual image patch similarity (LPIPS)

³ Natural Image Quality Evaluator (NIQE)

⁴ NRQM

⁵ PIQE

⁶ Robotics

⁷ New Trends in Image Restoration and Enhancement (NTIRE)

⁸ computer vision and pattern recognition (CVPR)

⁹ Perceptual Image Restoration and Manipulation (PIRM)



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران

www.ieeec.ir



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

۲.۳. مجموعه‌ی داده

مجموعه‌ی داده‌های مورد نیاز برای پژوهش‌های حوزه بینایی ماشین و به صورت خاص، برای آموزش شبکه‌ها در فرایند آموزش و ارزیابی تصاویر فراوضوح که مورد استفاده قرار می‌گیرند، در ادامه بررسی می‌شوند. DIV2K شامل تصویری با میانگین تعداد، ۲.۷ مگاپیکسل، از محیط زیست، گیاهان، جانوران، مردم و مناظر است. MCSR، EDSR، RDN، CRN، ERN، از این دیتاست برای آموزش و ارزیابی شبکه و Dilated-RDN، DSAN و DBCN فقط برای آموزش شبکه استفاده کرده‌اند. از اینجا^۱ دانلود کنید. ImageNet شامل ۳.۲ میلیون تصویر از پستانداران، پرندگان، ماهی‌ها، خزندگان، دوزیستان، وسایل نقلیه، مبلمان، آلات موسیقی، زمین‌شناسی، ابزار، گل‌ها و میوه‌ها، برای اهداف توسعه، تجزیه و تحلیل داده‌ها است. ESPCN و SRDenseNet برای آموزش شبکه از این دیتاست استفاده کرده‌اند. از اینجا^۲ دانلود کنید. Set5 شامل پنج تصویر نوزاد، پرنده، پروانه، یک سر و یک زن، با فرمت PNG، با میانگین تعداد، ۱۱۳ هزار، پیکسل. از اینجا^۳ دانلود کنید. Set14 شامل ۱۴ تصویر انسان، حیوانات، حشرات، گل‌ها، سبزیجات و اسلایدها، با میانگین تعداد، ۲۳۰ هزار، پیکسل است. هر دو مجموعه داده‌ی، Set5 و Set14، توسط همه‌ی الگوریتم‌ها به جز، MCSR و DRDN برای ارزیابی شبکه استفاده شدند. از اینجا^۴ دانلود کنید. BSDS100 شامل ۱۰۰ تصویر از حیوانات، ساختمان‌ها، غذا، مناظر، مردم و گیاهان است. توسط الگوریتم‌های VDSR، EDSR، CRN، ERN، DRCN، DRRN، GLRL، FGLRL، SRDenseNet، RDN، Dilated-RDN، DBCN و SICNN به عنوان مجموعه داده، برای ارزیابی شبکه، استفاده شد. از اینجا^۵ دانلود کنید. BSDS200 شامل ۲۰۰ تصویر از حیوانات، ساختمان‌ها، مناظر، مردم و گیاهان، با میانگین تعداد، ۱۵۴ هزار پیکسل، توسط الگوریتم‌های VDSR، DRRN، GLRL، FGLRL و Dilated-RDN برای آموزش، FSRCNN و ESPCN برای ارزیابی و DRDN هم برای آموزش و هم برای ارزیابی، استفاده کردند. Urban100 شامل ۱۰۰ تصویر از معماری، شهرها و سازه‌های شهری، با میانگین تعداد، ۷۷۴ هزار پیکسل، توسط الگوریتم‌های، VDSR، EDSR، CRN، ERN، DRCN، FGLRL، SRDenseNet، RDN، Dilated-RDN، DBCN و SICNN فقط برای ارزیابی شبکه استفاده شد. از اینجا^۶ دانلود کنید. Manga109 شامل تصاویر کارتون، با میانگین تعداد ۹۷ هزار پیکسل، فقط برای ارزیابی مدل‌های، RDN و SICNN استفاده شده است. از اینجا^۷ دانلود کنید. برخی از مجموعه‌ی داده‌های ذکر شده در بالا، فقط تصویر با وضوح بالا ارائه می‌دهند، برخی فقط تصویر با وضوح پائین. ترکیب مجموعه داده‌های متعدد، برای آموزش و ارزیابی، محبوب هست.

۲.۴. شبکه‌های عصبی

شبکه‌های عصبی زیربنای یادگیری عمیق هستند، که وظیفه‌ی تخمین یک تابع ناشناخته را دارد، که از در کنار هم قرارگرفتن چندین نورون مصنوعی، تشکیل شده است. در ادامه این بخش به معرفی اجمالی، بخش‌های یک شبکه‌ی عصبی مصنوعی می‌پردازیم. نورون، ساختار پایه‌ی شبکه‌های عصبی مصنوعی، نورون‌ها هستند که ایده اصلی طراحی آنها، از نورون‌های مغز انسان الهام گرفته شده است. نورون‌ها از سه بخش، ورودی، واحد پردازش و خروجی تشکیل شده‌اند. وزن،

¹ European Conference on Computer Vision (ECCV).

² <https://data.vision.ee.ethz.ch/cvl/DIV2K/>

³ <https://image-net.org/download.php>

⁴ <https://uofi.box.com/shared/static/kfahv87nfe8ax910l85dksyl2q212voc.zip>

⁵ <https://uofi.box.com/shared/static/igsnfieh4l268l926l8xbklwsnnk8we9.zip>

⁶ <https://uofi.box.com/shared/static/qgetsplb8txrksm9to9x01zfa4m61ngq.zip>

⁷ <https://uofi.box.com/shared/static/65upg43jzd0a4cswsqgl6o6ixube6klm.zip>

⁸ <http://www.manga109.org/en/>



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

مقیاسی برای بخش‌بندی کردن نرون‌های ورودی است. در طول زمان آموزش، وزنهای هر نرون ورودی، بروزرسانی می‌شود، بروزرسانی شدن، یعنی ورودی‌هایی که اهمیت بیشتری دارند، وزن بیشتر دریافت می‌کنند، اگر نرون (هایی)، بی‌اهمیت باشد، مقدار وزنی صفر دریافت می‌کند. بایاس، بر روی ورودی اثر گذار است، که به صورت اضافه شدن به حاصل ضرب وزن در ورودی اضافه می‌شود. بایاس یکی از اجزای خطی هست. تابع فعال‌سازی، یک تابع غیر خطی است که بعد از به پایان رسیدن کار اجزای خطی با ورودی، به آن اعمال می‌شود. این تابع وظیفه‌ای که دارد، تبدیل سیگنال‌های ورودی به سیگنال‌های خروجی است. پرکاربردترین توابع فعال‌سازی، ReLU، Sigmoid، Softmax را می‌توان نام برد. لایه مخفی ورودی، وظیفه دریافت ورودی را دارد. لایه (های) میانی، وظیفه پردازش اطلاعات را دارند، نام دیگرشان، لایه (های) مخفی هست. لایه‌ی خروجی هم آخرین لایه‌ی شبکه عصبی هست که وظیفه‌ی تولید خروجی را دارد. تابع هزینه، وظیفه‌ی پیش‌بینی خروجی شبکه را دارد. هنگامی که شبکه اشتباهی می‌کند، تابع هزینه، آن را جریمه می‌کند. در دو نوع، توابع زیان مربوط به الگوریتم‌های دسته بندی^۱ و توابع زیان مربوط به رگرسیون^۲. در این قسمت به معرفی چند تابع زیان پرکاربرد، می‌پردازیم. تابع زیان میانگین مربعات خطا^۳، میانگین مربعات فاصله بین مقدار پیش‌بینی و مقدار واقعی را محاسبه می‌کند، به دلیل اینکه در محاسبه MSE، از توان دو استفاده می‌شود، معمولاً تابع هزینه L2 هم گفته می‌شود.

میانگین قدرمطلق خطا^۴، همانند MSE، با معیار تفاضل مقدار واقعی و مقدار پیش‌بینی بدست می‌آید ولی جهت جهت این تفاضل را در نظر نمی‌گیرد و با L1 نمایش داده می‌شود.

نسبت یادگیری، به نسبت کاهش هزینه‌ها گفته می‌شود. تعادل بین نسبت یادگیری به شبکه کمک می‌کند تا از حالت بهینه عبور نکند و شبکه در زمان مناسب آموزش ببیند. بسته‌ها، همان ارسال ورودی‌ها به صورت بسته‌های کوچک هست، بجای ارسال یکجای تمام اطلاعات، آنها را به صورت بسته ارسال می‌کنیم تا مدل جامع‌تر باشد.

۳. ادبیات موضوع

30 mm

همان‌طور که ذکر شد، مسئله‌ی فراوضوح تک تصویر، یکی از چندین مسئله در حوزه فراوضوح می‌باشد. با فرض داشتن تک تصویر، با وضوح پایین، چندین راهکار برای افزایش وضوح تصویر وجود دارد که این روش‌ها، به قبل و بعد از بکارگیری یادگیری عمیق، برای بدست آوردن تصویر با وضوح بالا، تقسیم بندی می‌شوند. از زمان بکارگیری یادگیری عمیق، برای بازسازی تصویر فراوضوح، شبکه‌های متنوعی با الهام از نخستین کارهای یادگیری عمیق، پیشنهاد شده است. این روش‌ها را می‌توان، به بصورت کلی در چهار گروه بیان کرد. مدل‌های مبتنی بر شبکه‌های پیچشی کم عمق^۵، مدل‌های

¹ Classification

² Regression

³ Mean Square Error (MSE)

⁴ Mean Absolute Error (MAE)

⁵ models based on shallow CNN



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

مبتنی بر یادگیری باقیماده^۱، مدل‌های مبتنی بر ترکیب ویژگی‌های سلسله مراتبی^۲ و مدل‌های مبتنی بر شبکه‌های تخصصی^۳.

۱) مدل‌های بازسازی بر اساس شبکه‌های کم عمق

در روش خلاقانه و نوآورانه‌ی، یادگیری عمیق ارایه شده در سال ۲۰۱۴، که فراوضوح تصویر با شبکه‌های پیچشی^۴ [14]، نامیده شد، که مستقیماً یک نقشه برداری سرتاسری بین تصاویر با وضوح پایین و تصاویر با وضوح بالا را انجام داده، رابطه نگاشت بین آنها را با کمک شبکه پیچشی یاد می‌گیرد. فراوضوح تصویر با شبکه‌های پیچشی، متشکل از سه لایه پیچشی است که سه بخش استخراج و نمایش بلوک‌های تصویر^۵، رابطه نگاشت غیرخطی^۶ و بازسازی تصویر^۷ فراوضوح را محقق می‌کند. براساس نتایج تجربی که بدست آمده، نسبت پیک سیگنال به نویز، با افزایش نقشه‌های ویژگی در هر لایه، افزایش پیدا می‌کند، که به معنی این است که ویژگی‌های بیشتر می‌تواند بازسازی نهایی را بهبود ببخشد. گرچه می‌دانیم که با افزایش نقشه‌های ویژگی، افزایش پارامترهای بیشتر، اجتناب ناپذیر است و به دنبال آن، هزینه‌ی محاسبات افزایش پیدا خواهد کرد. هرچند این روش ساختاری ساده دارد و می‌توان اندازه‌های مختلفی از فیلترها را تنظیم کرد تا از اطلاعات در دسترس در کل عملیات استفاده کرد، ولی پیچیدگی محاسبات n^2 برابر افزایش می‌یابد.

شبکه عصبی کارآمد پیچشی زیرپیکسلی^۸ [27]، با بهره‌گیری از شبکه پیچشی، برای نمونه برداری از تصویر با وضوح پایین، به تصویر با وضوح بالا، یک لایه پیچشی زیرپیکسلی^۹ را طراحی و استفاده می‌کند. این روش سریعتر از فراوضوح تصویر با شبکه‌ی پیچشی است، زیرا تعداد کانولوشن‌های استفاده شده کوچک‌تر می‌شوند، فعال‌سازی واحد خطی اصلاح شده^{۱۰} به کار رفته، عملکرد بهتری در این مدل ارایه می‌دهد. ایرادی که این روش دارد، عدم توانایی استفاده به طور کامل، از اطلاعات ویژگی‌های لایه‌های سطح پایین است.

فراوضوح شبکه‌های پیچشی سریع^{۱۱} [28]، لایه پیچشی SRCNN را بهبود می‌بخشد، لایه دیکانولوشن^{۱۲} را برای تحقق نمونه برداری بالا معرفی می‌کند. لایه دیکانولوشن که به جای درون‌یابی دو مکعبی استفاده شده است، سرعت اجرا و عملکرد را بهبود بخشد. چون تعداد فیلترها کمتر و کوچک‌تر بود، که باعث شد تا مصرف حافظه به میزان قابل توجهی کاهش یابد، برخی از پارامترهای اضافی حذف شد و شبکه را کاراتر آموزش داد. در عوض ایراداتی هم داشت، از جمله: از اطلاعات ویژگی‌های سطح پایین استفاده نمی‌کند، فقط ویژگی‌های سطح بالا، در آخرین لایه، برای بازسازی استفاده شده است.

¹ models based on residual learning

² models based on hierarchical feature fusion

³ models based on GANs

⁴ Super-resolution convolutional neural network (SRCNN)

⁵ Patch extraction and representation

⁶ Nonlinear mapping

⁷ Reconstruction

⁸ Efficient sub-pixel convolutional neural network (ESPCN)

⁹ sub-pixel

¹⁰ rectified linear unit (ReLU)

¹¹ Fast SRCNN (FSRCNN)

¹² deconvolution



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران

www.ieeec.ir



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

۲) مدل های بازسازی مبتنی بر یادگیری باقی مانده

شبکه‌های پیچشی بسیار عمیق¹ [29]، توانست با ترکیب ویژگی‌های لایه سطح پایین با ویژگی‌های سطح بالا و با استفاده از اتصال پرش²، عملکرد مدل را بهبود ببخشد. بنابراین اتصال پرش توانست مشکل گرادیان محو شونده را که از افزایش لایه‌ها بوجود آمده بود را حل کند. یادگیری باقیمانده³ نسبت به فروضوح شبکه‌ی پیچشی، دو مزیت دارد. اول، شبکه سریع‌تر همگرا شد، دوم، مقدار ارزیابی نسبت پیک سیگنال به نویز، بهبود پیدا کرد. ولی چون از درونیایی دو مکعبی به عنوان نمونه برداری استفاده کرد، زمان محاسبات افزایش پیدا کرد و حافظه سنگین تری مصرف شد، مشکل گرادیان محو شونده با افزایش عمق اتفاق می‌افتد، فقط ویژگی‌های سطح بالا برای بازسازی در آخرین لایه استفاده شد، با محدود کردن پیکسل‌های تصویر با وضوح پایین، نتوانست ویژگی‌های غنی و معنی‌دار را استخراج کند و عدم وجود ویژگی‌های محلی، که منجر به کاهش عملکرد می‌شود.

مدل بهبود یافته‌ی مبتنی بر یادگیری باقیمانده⁴ [30]، با الهام از فرواضوح تصویر خیلی عمیق و معماری شبکه باقیمانده فرواضوح تصویر، برای غلبه بر مشکل زمان محاسبات سنگین و مصرف حافظه به دلیل استفاده از درونیایی دو مکعبی، به عنوان یک روش نمونه‌برداری سطح بالا پیشنهاد شد. شامل سه قسمت اصلی، استخراج ویژگی، قسمت بلوک باقیمانده⁵ و قسمت نمونه‌برداری است. واحد باقیمانده ساده شده، فقط شامل دو لایه پیچشی و یک لایه فعال‌سازی، واحد خطی اصلاح شده است، بنابراین پارامترها و پیچیدگی کل شبکه کاهش می‌یابد. ایده بلوک باقیمانده از شبکه باقیمانده فرواضوح و ایده اتصال پرش، از فرواضوح خیلی عمیق بود. لایه نرمال‌سازی دسته‌ای⁶، را که اندازه لایه مشابه قبلی است را حذف می‌کند تا در حافظه پردازنده گرافیک صرفه جویی کند، با بکارگیری یادگیری باقیمانده، به شبکه کمک می‌کند تا سریعاً همگرا شود و عملکرد بهتر را بدست آورد، از کانولوشن زیر پیکسل به عنوان ماژول نمونه برداری استفاده می‌کند تا زمان محاسبه و مصرف حافظه را کاهش دهد. از طرفی با محدود کردن پیکسل‌های تصویر با وضوح پایین و عدم استفاده از ویژگی‌های محلی، میزان عملکرد کاهش پیدا می‌کند و ویژگی‌های غنی و معنی‌دار استخراج نمی‌شوند و چون بیش از حد بر روی بهبودهای بدست آمده از طریق افزایش قابل ملاحظه عمق شبکه، تمرکز می‌کند، پارامترهای عظیم تولید می‌شود و منابع محاسباتی بیشتری مصرف می‌شود [2].

شبکه‌ی پیچشی بازگشتی عمیق⁷ [31]، با هدف برطرف کردن دشواری همگرایی شبکه، که با افزایش پارامترها در شبکه عمیق رخ می‌داد، پیشنهاد شد، در روش پیشنهادی، با عمیق‌تر شدن شبکه، تعداد پارامترهای وزن افزایش نمی‌یابد. برای غلبه بر دشواری همگرایی در آموزش شبکه، نظارت بازگشتی و اتصال پرش در شبکه معرفی شد و هنگام بازسازی، هر لایه بازگشتی، به تصویر با وضوح پایین اضافه می‌شود، تصویر بازسازی شده‌ی نهایی، با جمع وزنی نتایج بازسازی شده‌ی میانی بدست می‌آید. شبکه‌ی پیچشی بازگشتی عمیق، مشکل شبکه‌های فرواضوح کانولوشن را که به لایه‌های بیشتر، داده‌های بیشتر و پارامترهای بیشتر، برای جلوگیری از برازش بیش از حد نیاز دارد را برطرف کرد. با جمع آوری تمام خروجی‌های میانی، از هر واحد بازگشتی، عملکرد شبکه را بهبود بخشید [2]. ولی نظارت بر روی هر بازگشت، یک فرآیند

¹ Very Deep Super Resolution (VDSR)

² Skip connection

³ residual learning

⁴ Enhanced deep residual networks for super-resolution (EDSR)

⁵ residual block

⁶ batch normalization

⁷ deep-recursive convolutional network (DRCN)



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

سنگین هست، فقط یک نوع وزن، در بین تمام لایه‌های پیچشی مشترک است و همچنان مشکل ناپدید شدن گرادیان با عمیق‌تر شدن شبکه اتفاق می‌افتد.

شبکه‌ی باقیمانده بازگشتی عمیق¹ [32]، مشابه شبکه‌ی پیچشی بازگشتی عمیق، از بلوک‌های متراکم باقیمانده برای همجوشی ویژگی‌های محلی استفاده می‌کند، یادگیری باقیمانده محلی، به مشکل کاهش عملکرد در اکثر شبکه‌های عمیق کمک می‌کند. با به اشتراک گذاشتن بلوک بازگشتی، دقت را با افزایش عمق، بدون اضافه کردن پارامترهای وزنی بهبود بخشیده و با طراحی یک بلوک بازگشتی با ساختار چند مسیره، هزینه‌ی نظارت که با هر بازگشت، در شبکه‌ی پیچشی بازگشتی عمیق، اضافه می‌شد را حذف کرد. ایرادی که به این ساختار شبکه می‌توان گرفت، عدم استفاده از تمام خروجی‌ی هر واحد باقیمانده است.

۳ مدل‌های بازسازی براساس ترکیب ویژگی سلسله مراتبی

ما می‌دانیم که بازسازی هر پیکسل، در یک تصویر با وضوح پایین، ارتباط نزدیکی با پیکسل‌های اطراف همان تصویر دارد. بر اساس همین دانش، قبل از بازسازی یک تصویر با وضوح بالا، انتظار داریم تا حد امکان اطلاعات تصویر با وضوح پایین را استخراج کنیم، برای این کار، نیاز به استفاده از اطلاعات ویژگی سلسله مراتبی استخراج شده از شبکه است. شبکه‌ی حافظه² [33]، از بلوک‌های حافظه³، به عنوان واحد شبکه و از اتصالات پرش چند مسیره بین بلوک‌های حافظه در شبکه استفاده می‌کند. هدف، یادگیری تطبیقی، دارای عملکرد حافظه مداوم باشد.

شبکه‌های متراکم متصل⁴ [34]، بلوک‌های متراکم⁵ را به عنوان واحدهای اصلی می‌گیرد و در خروجی، هر واحد متراکم را از طریق اتصال پرش برای ترکیب ویژگی‌های سلسله مراتبی به لایه پیچشی بعدی، متصل می‌کند. با استفاده از یک شبکه‌ی متراکم، که به جریان اطلاعات و گرادیان کمک می‌کند، توانست بر مشکل گرادیان ناپدید شونده غلبه کند. چون از دکانولوشن به عنوان ماژول نمونه برداری استفاده می‌کند، محاسبات سریع‌تر انجام می‌شوند. از آنجایی که میدان پذیرنده، متناسب با عمق است، می‌توان از مقدار زیادی اطلاعات زمینه‌ای، در تصاویر با وضوح پایین، برای استنتاج اطلاعات با فرکانس بالا، در تصاویر با وضوح بالا، استفاده کرد. اما آموزش شبکه‌ی گسترده‌تر، با بلوک‌های متراکم، دشوارتر خواهد بود.

شبکه‌ی متراکم باقیمانده⁶ [35]، شبکه‌ای از ترکیب اتصالات باقیمانده و اتصال متراکم، می‌سازد. شبکه‌ی متراکم باقیمانده، لایه گلوگاه یک در یک را پس از اتصال متراکم، اضافه می‌کند و یادگیری باقیمانده‌ی محلی را از طریق اتصال پرش یکسان، معرفی می‌کند. مکانیسم حافظه پیوسته⁷، معرفی شد که به وضعیت شبکه‌ی متراکم باقیمانده قبلی اجازه می‌دهد تا به هر لایه از شبکه‌ی متراکم باقیمانده‌ی فعلی، دسترسی مستقیم داشته باشد. شبکه‌ی متراکم باقیمانده با استفاده از ترکیب ویژگی‌های محلی⁸، که آموزش شبکه را تثبیت می‌کند. نرخ رشد بیشتری را امکان‌پذیر می‌کند. اما

¹ deep recursive residual network (DRRN)

² Memory Network (MemNet)

³ Memory Block

⁴ Dense Network (DenseNet)

⁵ Dense Block (DBs)

⁶ Residual Dense Network (RDN)

⁷ Contiguous memory (CM)

⁸ local feature fusion (LFF)



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

افزایش قابل ملاحظه عمق، پارامترهای عظیمی را به وجود آورده است که در پی آن مصرف بیشتر منابع محاسباتی رخ می‌دهد.

۴ مدل‌های بازسازی بر اساس شبکه‌های تخصصی

شبکه‌ی فراوضوح مولد تخصصی^۱ [36]، یک شبکه‌ی ژنراتور عمیق، با چیدن بلوک‌های باقیمانده ساخته می‌شود و یک شبکه‌ی تشخیص دهنده، متشکل از هشت لایه پیچشی، به طور همزمان ساخته می‌شود، در نهایت از طریق بهینه‌سازی تناوب بازی مولد و متمایز کننده، تعادل بین دو شبکه حاصل می‌شود. در روش پیشنهادی شبکه‌ی فراوضوح مولد تخصصی، عملکرد زیان مولد را بهینه می‌کند و زیان ادراکی را ارائه می‌کند.

آدریان بولات و همکاران [37]، با استفاده از تصاویر جفت نشده وضوح پایین و وضوح بالا، برای آموزش شبکه‌های مولد تخصصی، یک روش تخریب نمونه‌برداری پایین، تصویر را پیشنهاد کردند. این باعث می‌شود شبکه‌های مولد متخصص، فرایند تخریب تصاویر واقعی را، بهتر یاد بگیرند و نتایج بازسازی را واقعی‌تر کنند.

روش‌های دیگر: شبکه‌های پیچشی چند متصل برای فراوضوح^۲ [38]، برای استفاده از ویژگی‌های سطح پایین و مشکل مشکل گرادیان محو شونده که ایراد شبکه‌ی فراوضوح عمیق بهبود یافته بود، در شبکه‌ی فراوضوح خیلی عمیق، هم یادگیری باقی‌مانده، هم نگاشت غیر خطی، فقط در لایه اول و آخر اتخاذ می‌شد، در شبکه‌های پیچشی چند متصل برای تصاویر فراوضوح، یادگیری باقیمانده از تکنیک الحاق برای به هم پیوستن ویژگی‌ها به جای اضافه کردن ویژگی‌های مانند شبکه‌ی فراوضوح عمیق بهبود یافته، استفاده می‌کند. تابع از دست دادن طراحی سفارشی مورد استفاده در شبکه‌های پیچشی چند متصل برای تصاویر فراوضوح، انعطاف‌پذیری را برای مدل فراهم می‌کند. ویژگی‌های غنی و معنی دار در ویژگی‌های محلی، استخراج و با ویژگی‌های سطح بالا از طریق عملیات الحاق ترکیب می‌شوند، که امکان عملکرد بهتر در مدل را فراهم می‌کند.

شبکه‌ی باقیمانده‌ی آبخاری^۳ [39]، برای غلبه بر پارامترهای عظیم که در شبکه‌ی فراوضوح عمیق بهبود یافته بود، ناشی از افزایش عمق ایجاد می‌شد، پیشنهاد شد. شبکه‌ی باقیمانده‌ی آبخاری، با الهام از شبکه‌ی فراوضوح عمیق بهبود یافته، با جایگزین کردن گروه مشترک محلی^۴، بجای بلوک باقیمانده، ابداع شد. ساختار اتصال آبخاری و مسیر باقیمانده‌ی دوگانه‌ی سرتاسری را برای حل مشکل نیاز به پارامترهای عظیم، برای به دست آوردن عملکرد بالا معرفی کرد و عملکرد آن در مقایسه با شبکه‌ی فراوضوح عمیق بهبود یافته، (به تعداد پارامترهای چهار برابر کمتر از شبکه‌ی فراوضوح عمیق) یکسان است. بنابراین مقدار زیادی از حافظه را ذخیره می‌کند.

شبکه‌ی جهانی یادگیری باقیمانده^۵ [40]، با الهام از ساختار، شبکه‌ی پیچشی بازگشتی عمیق، شبکه‌ی عصبی پیچشی پیچشی تصویر فراوضوح و شبکه‌ی باقیمانده‌ی بازگشتی عمیق، پیشنهاد شد. طراحی پایه را از شبکه‌ی عصبی پیچشی تصویر فراوضوح، طراحی خروجی میانی را از شبکه‌ی پیچشی بازگشتی عمیق و طراحی بلوک بازگشتی را از شبکه‌ی باقیمانده‌ی بازگشتی عمیق، به کارگرفت و همه را ترکیب کرد. در نگاشت غیر خطی، از یک بلوک باقیمانده محلی^۶، استفاده شد و هر بلوک باقیمانده، ساختاری مشابه با بلوک بازگشتی در شبکه‌ی باقیمانده‌ی بازگشتی عمیق دارد. ابتدا، یک

¹ Super Resolution Generative Adversarial Network (SRGAN)

² Multi-Connected Convolutional Network for Super-Resolution (MCSR)

³ Cascading Residual Network (CRN)

⁴ locally sharing group (LSG)

⁵ Global Learning Residual Learning Network (GLRL)

⁶ local residual block (LRB)



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

واحد خطی یک‌سو کننده پارامتر^۱، بعد از لایه پیچشی اعمال شد و در گام دوم، یک فرایند اضافی به ویژگی ورودی، قبل از اضافه شدن آنها به هر واحد باقیمانده انجام شد. همه خروجی‌های میانی از هر بلوک باقیمانده محلی، یک مرحله مشابه را در شبکه‌ی پیچشی بازگشتی عمیق، برای اهداف بازسازی انجام دادند. پذیرش لایه واحد خطی اصلاح شده، که شامل ضرب منفی قابل یادگیری، برای جلوگیری از ساختار مرگ، ناشی از گرادین صفر، در واحد خطی، اصلاح شده است.

شبکه‌ی یادگیری باقیمانده‌ی سراسری سریع^۲ [41]، در ساختار شبکه‌ی یادگیری باقیمانده‌ی سراسری سریع، طراحی بر پایه شبکه‌ی سریع فراوضوح پیچشی صورت گرفت. شبکه‌ی یادگیری باقیمانده‌ی سراسری سریع از پنج بخش تشکیل شده است، استخراج وصله^۳، کوچک شدن^۴، نگاشت غیرخطی^۵، گسترش^۶ و بازسازی^۷. در شبکه‌ی یادگیری باقیمانده‌ی سراسری سریع، درون‌یابی دومکعبی به عنوان هسته نمونه برداری استفاده شد. زمان اجرای مدل نسبت به شبکه‌ی یادگیری باقیمانده‌ی سراسری سریع و شبکه‌ی جهانی یادگیری باقیمانده، دو برابر سریع‌تر است و از شبکه‌ی فراوضوح خیلی سریع، سریع‌تر، اما نسبت به فراوضوح تصویر با شبکه‌های پیچشی، کندتر است. سرعت زیاد به این دلیل است که لایه کوچک شونده، که ابعاد ویژگی‌های استخراج وصله را کاهش می‌دهد، به کاهش منابع حافظه در زمان اجرا کمک می‌کند. شبکه‌ی متراکم باقیمانده‌ی عمیق^۸ [42]، اتصالات پرش، فقط مابین ویژگی‌های ورودی و خروجی واحد باقیمانده، اعمال می‌شود. شبکه‌ی متراکم باقیمانده‌ی عمیق، متشکل از استخراج ویژگی‌های کم عمق^۹، شبکه متراکم باقیمانده^{۱۰} و بازسازی همجوشی^{۱۱} است. تفاوت اصلی بین شبکه‌ی فراوضوح عمیق بهبودیافته و مدل پیشنهادی، در لایه‌های بلوک‌های باقی مانده در باقیمانده‌ی متراکم^{۱۲}، مشهود است.

شبکه توجه فضای متراکم^{۱۳} [43]، از شبکه‌ی متراکم باقیمانده، الهام گرفته شده است. اضافه شدن مازول توجه بلوک پیچشی^{۱۴}، با توجه بیشتر به کانال مفید ویژگی‌ها، مزیت بسیار خوبی به شبکه داد و توانایی تشخیص آن را افزایش داد. از تمام لایه‌های ویژگی و وابستگی بین کانال‌ها از طریق اتصال متراکم استفاده کرد و استقرار یادگیری باقیمانده، عملکرد مدل را افزایش داد.

شبکه‌ی عصبی کانولوشن دو شاخه ای^{۱۵} [44]، در این ساختار، شبکه به دو شاخه تقسیم شد، در اولین شاخه یک لایه کانولوشن با واحد خطی اصلاح شده نشستی^{۱۶}، را به عنوان تابع فعال سازی پذیرفت، در حالی که شاخه دیگر لایه پیچشی‌ی گشاد شده با واحد خطی اصلاح شده نشستی را به عنوان تابع فعال سازی پذیرفت. سپس خروجی هر شاخه از طریق فرآیند الحاق قبل از نمونه‌برداری مجدد، ترکیب می‌شود. نکته دیگری که نشان داد، شبکه‌ی عصبی کانولوشن دو شاخه ای با سایر شبکه‌ها متفاوت است، ترکیب هر دو درون‌یابی دو مکعبی، با سایر روش‌های نمونه برداری، مانند هسته

¹ parameter rectifier linear unit (PReLU)

² Fast Global Learning Residual Learning Network (FGLRL)

³ patch extraction

⁴ shrinking

⁵ non-linear mapping

⁶ expanding

⁷ reconstruction

⁸ Deep Residual Dense Network (DRDN)

⁹ shallow feature extraction

¹⁰ residual dense network

¹¹ fusion reconstruction

¹² residual-in-residual-dense blocks (residual-in-RDB)

¹³ Dense Space Attention Network (DSAN)

¹⁴ convolution block attention module (CBAM)

¹⁵ Dual-Branch Convolutional Neural Network (DBCN)

¹⁶ Leaky Rectified Linear Unit (LReLU)



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبان



موسسه آموزش عالی ادیبان

www.ieeec.ir

دکانولوشن، برای فرآیند بازسازی بود. چند جنبه سودمند را می‌توان از دیدگاه شبکه‌ی عصبی کانولوشن دو شاخه‌ای مشاهده کرد. اولین، ساختار دو شاخه‌ای، مشکل شبکه‌ی پیچیده‌ای را که اغلب در شبکه‌های مبتنی بر مسیر زنجیره‌ای مشاهده می‌شود، حل کرد. دوم، استفاده از یک فیلتر پیچشی گشاد شده، کیفیت تصویر را در طول بازسازی افزایش داد. سوم، یادگیری باقیمانده، برای دستیابی سریع‌تر به همگرایی، مزیت بیشتری به مدل داد. شبکه‌ی عصبی کانولوشن دو شاخه‌ای، مشکل اکثر شبکه‌های فراوضوح پیچشی را که به سادگی، لایه‌های پیچشی را به صورت زنجیره‌ای روی هم می‌چینند، که منجر به زمان طولانی‌تر و پیچیدگی حافظه می‌شود را برطرف می‌کند و عملکرد مدل را با ترکیب، دو ویژگی از هسته دو مکعبی و هسته دکانولوشن، افزایش می‌دهد.

۴. نتیجه‌گیری (B Nazanin 12 pt, Bold) (فونت: B Nazanin، اندازه فونت ۱۲ و ضخیم)

در این مقاله روش‌های نوین در حوزه پردازش تصویر، برای فراوضوح کردن تصویر را مورد بررسی قرار دادیم و معایب و مزایای روش‌های ارائه شده در این حوزه را بیان کردیم، روش‌های نوآورانه‌ای که عمدتاً بر پایه شبکه‌های عمیق در لبه دانش ارائه شده و پیاده‌سازی شده‌اند.

۵. قدردانی

در انتها از استاد عزیز، محمد علی بالافر به پاس زحمات بی بدیلشان که بنده را در راستای نوشتن این مقاله، راهنمایی کردند سپاسگذارم.

۶. مراجع

- [1] K. Li, S. Yang, R. Dong, X. Wang, and J. Huang, "Survey of single image super-resolution reconstruction," *IET Image Process.*, vol. 14, no. 11, pp. 2273–2290, 2020, doi: 10.1049/iet-ipr.2019.1438.
- [2] Y. K. Ooi and H. Ibrahim, "Deep learning algorithms for single image super-resolution: A systematic review," *Electron.*, vol. 10, no. 7, 2021, doi: 10.3390/electronics10070867.
- [3] R. Dahl and J. Shlens, "Pixel Recursive Super Resolution," *Iccv*, pp. 5439–5448, 2017.
- [4] X. Cheng and Z. Chen, "Multiple Video Frame Interpolation via Enhanced Deformable Separable Convolution," *IEEE Trans. Pattern Anal. Mach. Intell.*, 2021, doi: 10.1109/TPAMI.2021.3100714.
- [5] S. P. Belekos, N. P. Galatsanos, and A. K. Katsaggelos, "Maximum a posteriori video super-resolution with a new multichannel image prior," *Eur. Signal Process. Conf.*, vol. 19, no. 6, pp. 1451–1464, 2008.
- [6] X. Zhang, H. Dong, Z. Hu, W. S. Lai, F. Wang, and M. H. Yang, "Gated Fusion Network for Degraded Image Super Resolution," *Int. J. Comput. Vis.*, vol. 128, no. 6, pp. 1699–1721, 2020, doi: 10.1007/s11263-019-01285-y.

25 mm



موسسه آموزش عالی ادیبیان



موسسه آموزش عالی ادیبیان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبیان



موسسه آموزش عالی ادیبیان



www.ieeec.ir

- [7] J. Sun, J. Sun, Z. Xu, and H. Y. Shum, "Image super-resolution using gradient profile prior," *26th IEEE Conf. Comput. Vis. Pattern Recognition, CVPR*, 2008, doi: 10.1109/CVPR.2008.4587659.
- [8] S. Farsiu, M. D. Robinson, M. Elad, and P. Milanfar, "Fast and robust multiframe super resolution," *IEEE Trans. Image Process.*, vol. 13, no. 10, pp. 1327–1344, 2004, doi: 10.1109/TIP.2004.834669.
- [9] A. Laghrib, A. Hadri, A. Hakim, and S. Raghay, "A new multiframe super-resolution based on nonlinear registration and a spatially weighted regularization," *Inf. Sci. (Ny)*, vol. 493, pp. 34–56, 2019, doi: 10.1016/j.ins.2019.04.029.
- [10] W. Wang and Q. He, "A survey on emotional semantic image retrieval," *Proc. - Int. Conf. Image Process. ICIP*, no. May 2014, pp. 117–120, 2008, doi: 10.1109/ICIP.2008.4711705.
- [11] B. Thomas, K. Nasrollahi, and T. B. Moeslund, *A comprehensive survey Super-resolution : A comprehensive survey*. 2014.
- [12] V. H. Patil and D. S. Bormane, "Interpolation for super resolution imaging," *Innov. Adv. Tech. Comput. Inf. Sci. Eng.*, pp. 483–489, 2007, doi: 10.1007/978-1-4020-6268-1_85.
- [13] W. C. Siu and K. W. Hung, "Review of image interpolation and super-resolution," *2012 Conf. Handb. - Asia-Pacific Signal Inf. Process. Assoc. Annu. Summit Conf. APSIPA ASC 2012*, pp. 1–10, 2012.
- [14] C. Dong, C. C. Loy, K. He, and X. Tang, "Image Super-Resolution Using Deep Convolutional Networks," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 38, no. 2, pp. 295–307, 2016, doi: 10.1109/TPAMI.2015.2439281.
- [15] L. Zhang, H. Zhang, H. Shen, and P. Li, "A super-resolution reconstruction algorithm for surveillance images," *Signal Processing*, vol. 90, no. 3, pp. 848–859, 2010, doi: 10.1016/j.sigpro.2009.09.002.
- [16] W. W. W. Zou and P. C. Yuen, "Very low resolution face recognition problem," *IEEE Trans. Image Process.*, vol. 21, no. 1, pp. 327–340, 2012, doi: 10.1109/TIP.2011.2162423.
- [17] J. K. B, P. Huber, and Z. Feng, "Convolutional Neural Network Super Resolution for Face Recognition in Surveillance Monitoring," vol. 1, pp. 185–206, 2016, doi: 10.1007/978-3-319-41778-3.
- [18] J. S. Isaac and R. Kulkarni, "Super resolution techniques for medical image processing," *Proc. - Int. Conf. Technol. Sustain. Dev. ICTSD 2015*, 2015, doi: 10.1109/ICTSD.2015.7095900.
- [19] H. Greenspan, "Super-resolution in medical imaging," *Comput. J.*, vol. 52, no. 1, pp. 43–63, 2009, doi: 10.1093/comjnl/bxm075.
- [20] W. Shi *et al.*, "Cardiac image super-resolution with global correspondence using multi-atlas patchmatch.," *Med. Image Comput. Comput. Assist. Interv.*, vol. 16, no. Pt 3, pp. 9–16, 2013.
- [21] H. Chen *et al.*, "Real-world single image super-resolution: A brief review," *Inf. Fusion*, vol. 79, pp. 124–145, 2022, doi: 10.1016/j.inffus.2021.09.005.
- [22] Y. Huang, L. Shao, and A. F. Frangi, "Simultaneous super-resolution and cross-modality synthesis of 3D medical images using weakly-supervised joint convolutional sparse coding," *Proc. - 30th IEEE Conf. Comput. Vis. Pattern Recognition, CVPR 2017*, vol. 2017-Janua, pp. 5787–5796, 2017, doi: 10.1109/CVPR.2017.613.



موسسه آموزش عالی ادیبیان



موسسه آموزش عالی ادیبیان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبیان



موسسه آموزش عالی ادیبیان

www.ieeec.ir

- [23] H. A. Pierson and M. S. Gashler, "Deep learning in robotics: a review of recent research," *Adv. Robot.*, vol. 31, no. 16, pp. 821–835, 2017, doi: 10.1080/01691864.2017.1365009.
- [24] S. Anwar, S. Khan, and N. Barnes, "A Deep Journey into Super-resolution: A Survey," *ACM Comput. Surv.*, vol. 53, no. 3, pp. 1–21, 2020, doi: 10.1145/3390462.
- [25] W. Yang, X. Zhang, Y. Tian, W. Wang, J. H. Xue, and Q. Liao, "Deep Learning for Single Image Super-Resolution: A Brief Review," *IEEE Trans. Multimed.*, vol. 21, no. 12, pp. 3106–3121, 2019, doi: 10.1109/TMM.2019.2919431.
- [26] Z. Wang, J. Chen, and S. C. H. Hoi, "Deep Learning for Image Super-resolution : A Survey."
- [27] W. Shi *et al.*, "SR with Sub-Pixel," *Comput. Vis. Patter Recognit.*, pp. 1874–1883, 2016.
- [28] C. Dong, C. C. Loy, and X. Tang, "Accelerating the super-resolution convolutional neural network," *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 9906 LNCS, pp. 391–407, 2016, doi: 10.1007/978-3-319-46475-6_25.
- [29] J. Kim, J. K. Lee, and K. M. Lee, "Accurate Image Super-Resolution Using Very Deep Convolutional Networks," pp. 1646–1654.
- [30] H. Wang, K. Liao, B. Yan, and R. Ye, "Deep Residual Networks for Single Image Super-Resolution," *ACM Int. Conf. Proceeding Ser.*, pp. 66–70, 2019, doi: 10.1145/3341016.3341030.
- [31] J. Kim, J. K. Lee, and K. M. Lee, "Deeply-recursive convolutional network for image super-resolution," *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, vol. 2016-Decem, pp. 1637–1645, 2016, doi: 10.1109/CVPR.2016.181.
- [32] Y. Tai, J. Yang, and X. Liu, "Image Super-Resolution via Deep Recursive Residual Network," pp. 3147–3155.
- [33] Y. Tai, J. Yang, X. Liu, and C. Xu, "MemNet : A Persistent Memory Network for Image Restoration," pp. 4539–4547.
- [34] T. Tong, G. Li, X. Liu, and Q. Gao, "Image Super-Resolution Using Dense Skip Connections."
- [35] J. Xu, Y. Chae, B. Stenger, and A. Datta, "Dense bynet: Residual dense network for image super resolution," *Proc. - Int. Conf. Image Process. ICIP*, no. October 2018, pp. 71–75, 2018, doi: 10.1109/ICIP.2018.8451696.
- [36] C. Ledig *et al.*, "Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network," pp. 4681–4690.
- [37] A. Bulat, J. Yang, and G. Tzimiropoulos, "To learn image super-resolution, use a GAN to learn how to do image degradation first," *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 11210 LNCS, pp. 187–202, 2018, doi: 10.1007/978-3-030-01231-1_12.
- [38] J. Chu, J. Zhang, W. Lu, and X. Huang, "A Novel Multiconnected Convolutional Network for Super-Resolution," *IEEE Signal Process. Lett.*, vol. 25, no. 7, pp. 946–950, 2018, doi: 10.1109/LSP.2018.2820057.
- [39] R. Lan *et al.*, "Cascading and Enhanced Residual Networks for Accurate Single-Image Super-Resolution," *IEEE Trans. Cybern.*, vol. 51, no. 1, pp. 115–125, 2021, doi: 10.1109/TCYB.2019.2952710.
- [40] J. Hou, Y. Si, and L. Li, "Image Super-Resolution Reconstruction Method Based on Global and Local Residual Learning," *2019 IEEE 4th Int. Conf. Image, Vis. Comput.*



موسسه آموزش عالی ادیبیان



موسسه آموزش عالی ادیبیان

هشتمین کنگره ملی تازه‌های مهندسی برق و کامپیوتر ایران



موسسه آموزش عالی ادیبیان



موسسه آموزش عالی ادیبیان

www.ieeec.ir

ICIVC 2019, pp. 341–345, 2019, doi: 10.1109/ICIVC47709.2019.8981305.

- [41] J. Hou, Y. Si, and X. Yu, “A novel and effective image super-resolution reconstruction technique via fast global and local residual learning model,” *Appl. Sci.*, vol. 10, no. 5, p. 1856, 2020, doi: 10.3390/app10051856.
- [42] Y. R. Musunuri and O. S. Kwon, “Deep Residual Dense Network for Single Image Super-Resolution,” *Electron.*, vol. 10, no. 5, pp. 1–15, 2021, doi: 10.3390/electronics10050555.
- [43] C. Duanmu and J. Zhu, “The Image Super-Resolution Algorithm Based on the Dense Space Attention Network,” *IEEE Access*, vol. 8, pp. 140599–140606, 2020, doi: 10.1109/ACCESS.2020.3013401.
- [44] X. Gao, L. Zhang, and X. Mou, “Single Image Super-Resolution Using Dual-Branch Convolutional Neural Network,” *IEEE Access*, vol. 7, pp. 15767–15778, 2019, doi: 10.1109/ACCESS.2018.2889760.
- [45] X. Ji, Y. Cao, Y. Tai, C. Wang, J. Li, and F. Huang, “Real-world super-resolution via kernel estimation and noise injection,” *IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit. Work.*, vol. 2020-June, pp. 1914–1923, 2020, doi: 10.1109/CVPRW50498.2020.00241.
- [46] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image quality assessment: From error visibility to structural similarity,” *IEEE Trans. Image Process.*, vol. 13, no. 4, pp. 600–612, 2004, doi: 10.1109/TIP.2003.819861.
- [47] A. Horé and D. Ziou, “Image quality metrics: PSNR vs. SSIM,” *Proc. - Int. Conf. Pattern Recognit.*, pp. 2366–2369, 2010, doi: 10.1109/ICPR.2010.579.
- [48] A. Mittal, R. Soundararajan, and A. C. Bovik, “Making a ‘completely blind’ image quality analyzer,” *IEEE Signal Process. Lett.*, vol. 20, no. 3, pp. 209–212, 2013, doi: 10.1109/LSP.2012.2227726.